TÀI LIỆU ÔN TẬP

Chuẩn bị dữ liệu và thao tác đặc trưng

Quy trình 7 bước · key point từng bước · bảng so sánh · câu hỏi tự kiểm tra

Nguồn tài liệu

File	Tên	Nội dung chính
DL03a	Data Exploration (96 trang)	Thuộc tính và thang đo, loại tập dữ liệu, chất lượng dữ liệu, tiền xử lý (aggregation, sampling, giảm chiều, chọn/tạo đặc trưng, rời rạc hóa, chuẩn hóa), độ tương đồng, mật độ, EDA (thống kê, trực quan hóa)
DL03b	Feature Manipulation (42 trang)	Data preparation, data leakage, train/test/validation, k-fold CV, mã hóa phân loại, chuẩn hóa, rời rạc hóa, giảm chiều (extraction, selection)
DL03c	Feature Engineering and Missing Values	Feature engineering (one-to-one, one-to-many, many-to-one, many-to-many), feature construction, PCA/ICA/kernel PCA/autoencoder, giá trị thiếu (MCAR/MAR/MNAR) và imputation

Cách đọc tài liệu này

- Nội dung **không gắn nhãn** là lấy từ slide (đã đối chiếu).
- Nội dung gắn nhãn **[Mình]** là **phân tích, suy luận hoặc kiến thức ngoài slide** của người soạn. Đây là phần bạn nên cân nhắc kỹ nhất khi kiểm tra.
- Ký hiệu ⚠ đánh dấu **lỗi hoặc điểm lệch trong slide** mà mình phát hiện khi đối chiếu.
- Cuối mỗi bước có hộp **Tự kiểm tra** ghi rõ: đã đối chiếu nguồn gì, đâu là ý của tác giả slide, đâu là phân tích của mình, mức chắc chắn và phần chưa xác minh.
- Slide của giảng viên là nguồn duy nhất. Các nhận định kiểu "thường", "nên" trong slide là quy tắc kinh nghiệm của giảng viên, không phải định lý.

Bản đồ: mỗi bước dựa vào file nào

#	Bước	DL03a	DL03b	DL03c
1	Hiểu dữ liệu	Attribute, thang đo, loại tập dữ liệu	Các kiểu dữ liệu	—
2	Khám phá dữ liệu (EDA)	Thống kê mô tả, trực quan hóa, tương đồng, mật độ	—	—
3	Chất lượng và làm sạch	Noise, outlier, thiếu, trùng	Data cleaning	Giá trị thiếu, MCAR/MAR/MNAR, imputation
4	Chia dữ liệu và chọn mẫu	Sampling	Leakage, train/test/val, k-fold	—
5	Biến đổi biểu diễn	Aggregation, rời rạc hóa, chuẩn hóa	Mã hóa, chuẩn hóa, rời rạc hóa	Phân loại phép biến đổi 1-1, 1-n
6	Thao tác đặc trưng	Giảm chiều, chọn/tạo đặc trưng	Extraction, selection	Construction, PCA/ICA/kPCA/AE
7	Mô hình hóa và đánh giá	—	Generalisation, overfitting	Biểu đồ tỉ trọng công việc

BƯỚC 1

Khung quy trình tổng thể

Từ dữ liệu thô đến mô hình đáng tin

1.1. Quy trình 7 bước

1 Hiểu dữ liệu	2 Khám phá (EDA)	3 Chất lượng và làm sạch	4 Chia dữ liệu	5 Biến đổi biểu diễn	6 Thao tác đặc trưng	7 Mô hình và đánh giá

PHÂN TÍCH CỦA MÌNH (không có trong slide)

- Thứ tự 7 bước là cách **mình sắp xếp** từ ba file, không phải sơ đồ có sẵn trong slide. Thực tế các bước lặp lại nhiều lần (ví dụ phát hiện chất lượng kém ở bước 3 có thể quay lại bước 2).
- Slide chỉ nói rõ một ràng buộc thứ tự: **chia dữ liệu → chuẩn bị dữ liệu → mô hình hóa** (DL03b, trang data leakage).

1.2. Ba ý xuyên suốt

- **Data preparation ("data munging") chiếm hơn 80% thời gian và công sức của dự án** (DL03b). Riêng feature engineering khoảng 25% theo biểu đồ trong DL03c (xem bước 7).
- **Garbage in, garbage out**: chất lượng dữ liệu quyết định chất lượng mô hình (DL03b).
- Mỗi thuật toán học máy có yêu cầu dữ liệu khác nhau, và mỗi công cụ dùng định dạng khác nhau (DL03b). Vì vậy chuẩn bị dữ liệu phụ thuộc vào thuật toán sắp dùng.

1.3. Năm tác vụ trong data preparation (DL03b)

Tác vụ	Ý nghĩa
Data Selection	Xác định tập dữ liệu dùng, chọn đặc trưng, chọn mẫu (instance)
Data Cleaning	Sửa, điền (impute) hoặc loại giá trị sai, giá trị thiếu
Data Construction	Các thao tác tạo mới: feature construction, sinh mẫu, biến đổi đặc trưng
Integrate Data	Tạo bản ghi hoặc giá trị mới bằng cách kết hợp nhiều nguồn, gộp, aggregation
Format Data	Định dạng lại dữ liệu cho tiện mô hình hóa

1.4. Ba khía cạnh và năm nhiệm vụ tiền xử lý thường gặp (DL03b)

- **Ba khía cạnh:** định dạng dữ liệu (cho từng công cụ, phương pháp), chuẩn bị thí nghiệm (cách dùng dữ liệu), xử lý dữ liệu đầu vào.
- **Nhiệm vụ thường gặp:** data cleaning (nhận diện và sửa lỗi), data transforms (đổi thang đo/phân phối), dimensionality reduction (tạo biểu diễn gọn), feature selection (chọn biến liên quan), feature construction (suy ra biến mới).

1.5. Phân biệt ba khái niệm hay bị lẫn (DL03b)

Khái niệm	Chiều thay đổi	Bản chất	Diễn giải được?
Feature extraction	Giảm, d → m	Biến đổi vector gốc thành m đặc trưng mới giữ phần lớn thông tin	Không (mất danh tính từng đặc trưng)
Feature selection	Giảm	Chọn tập con nhỏ của đặc trưng gốc	Có
Feature construction	Tăng/đổi	Phát hiện quan hệ giữa các đặc trưng, bổ sung đặc trưng mới	Tùy phép toán

TỰ KIỂM TRA CỦA BƯỚC NÀY

- **Đối chiếu nguồn:** các ý lấy từ DL03b (trang 3, 4, 5, 6, 26) và DL03c (biểu đồ tỉ trọng). Con số "hơn 80%" và "25%" đo hai thứ khác nhau (toàn bộ chuẩn bị dữ liệu so với riêng feature engineering) nên không mâu thuẫn.
- **Ý tác giả và của mình:** thứ tự 7 bước là của mình; ràng buộc chia trước chuẩn bị là của slide.
- **Chắc chắn:** cao cho nội dung chép từ slide. Các con số 80%, 25% là nhận định của giảng viên, slide không đưa dẫn chứng gốc.

BƯỚC 2

Hiểu và khám phá dữ liệu

Nguồn chính: DL03a

2.1. Đối tượng và thuộc tính

- **Object** (còn gọi record, point, case, sample, entity, instance) được mô tả bởi một tập **attribute** (variable, field, characteristic, **feature**).
- Dữ liệu dạng bảng: mỗi dòng là một object, mỗi cột là một attribute.

Bốn thang đo (mỗi thang kế thừa phép toán của thang trước)

Thang	Ý nghĩa	Phép toán	Thống kê phù hợp	Ví dụ
Nominal	Chỉ phân biệt được các nhãn	=, ≠	mode, entropy, contingency correlation, χ^2 test	mã bưu điện, mã nhân viên, màu mắt, giới tính
Ordinal	Có thứ tự	Nominal + <, >	median, percentile, rank correlation, run test, sign test	xếp hạng, điểm số, {thấp, vừa, cao}
Interval	Hiệu giữa các giá trị có nghĩa	Ordinal + +, −	mean, độ lệch chuẩn, Pearson, t và F test	ngày tháng, nhiệt độ °C/°F
Ratio	Cả hiệu và tỉ lệ có nghĩa	Interval + ×, /	geometric mean, harmonic mean, percent variation	nhiệt độ Kelvin, tiền, số đếm, tuổi, khối lượng

- Nominal và ordinal thuộc nhóm **categorical/qualitative**. Interval và ratio thuộc nhóm **quantitative**.
- **Discrete**: tập giá trị hữu hạn hoặc đếm được (binary là trường hợp đặc biệt). **Continuous**: giá trị là số thực (máy tính biểu diễn bằng số dấu phẩy động hữu hạn chữ số).

PHÂN TÍCH CỦA MÌNH (không có trong slide)

- Mẹo phân biệt: interval không có "điểm 0 thật" (0°C không phải là không có nhiệt), ratio có (gấp đôi nghĩa là nhiều gấp đôi).
- Slide đặt câu hỏi về thang đo nhưng không ghi đáp án: số xe mỗi phút là **ratio** (count). Tuổi đã chia nhóm (0-4, 5-9,... hoặc <20, 21-30,... 41+) là **ordinal**: các nhóm có thứ tự nhưng việc gộp nhóm làm mất giá trị chính xác, và nhóm mở (<20, 41+) không có độ rộng xác định. Đây là suy luận của mình, slide không ghi đáp án.

⚠ LỖI / ĐIỂM LỆCH TRONG SLIDE

- Bảng thang đo (trang 6): cột ví dụ của **Ordinal** bị lặp đúng ví dụ của Nominal (mã bưu điện, mã nhân viên, màu mắt, giới tính). Ví dụ ordinal đúng nằm ở trang 5 (xếp hạng, điểm, tall/medium/short).

2.2. Các loại tập dữ liệu

Họ	Dạng cụ thể	Điểm cần nhớ
Record	Data matrix, Document data, Transaction data	Data matrix: ma trận m đối tượng × n thuộc tính số, mỗi đối tượng là một điểm trong không gian n chiều. Document data: mỗi tài liệu là vector đếm tần suất từ. Transaction data: mỗi giao dịch là một tập item (ví dụ giỏ hàng).
Graph	World Wide Web, cấu trúc phân tử (benzene C6H6)	Dữ liệu là nút và cạnh/liên kết.
Ordered	Spatial, temporal, sequential, genetic sequence, time series, spatio-temporal	Thứ tự hoặc vị trí là một phần của thông tin (chuỗi giao dịch, chuỗi gen, nhiệt độ theo tháng và vị trí).

2.3. Thống kê mô tả (summary statistics)

Nhóm	Đại lượng	Lưu ý
Biến phân loại	Tần suất, **mode**	Mode là giá trị xuất hiện nhiều nhất. Ví dụ slide: giới tính 'female' chiếm khoảng 60%.
Vị trí	**Mean**, **median**, trimmed mean	Mean rất nhạy với outlier. Median và trimmed mean **bền vững (robust)**.
Độ trải	Range, variance/độ lệch chuẩn, **IQR**	Range, variance nhạy với outlier. IQR bền vững; IQR = Q3 − Q1, chứa 50% giá trị ở giữa.
Percentile	x_p	p% quan sát nhỏ hơn x_p. Median là percentile thứ 50. Đa số thống kê tính được trong một lượt duyệt dữ liệu.

Tương quan giữa hai biến

Độ đo	Đo cái gì	Đặc điểm
Pearson ρ = cov(X,Y) / (sd(X)·sd(Y))	Quan hệ **tuyến tính**, trong [−1, 1]	Tính bằng cách chuẩn hóa rồi lấy tích vô hướng. Hay dùng làm độ đo tương đồng.
Spearman's rho	Pearson tính trên các **hạng**	Bền vững với outlier, không giả định phân phối chuẩn hay quan hệ tuyến tính.
Kendall's tau	$\tau = (N_s - N_d) / (n(n-1)/2)$	N_s: số cặp đồng thuận, N_d: số cặp bất đồng thuận.
Goodman–Kruskal gamma	$\gamma = (N_s - N_d) / (N_s + N_d)$	Cùng họ tương quan hạng, trong [−1, 1].

2.4. Trực quan hóa

KEY POINT

- Con người nhận ra mẫu hình, xu hướng và outlier rất tốt khi nhìn hình.
- **Representation**: ánh xạ đối tượng, thuộc tính, quan hệ thành điểm, đường, hình, màu. **Arrangement**: cách bố trí các phần tử, ảnh hưởng nhiều tới mức dễ hiểu.
- Tập minh họa trong slide: **Iris** (R.A. Fisher), 150 bông hoa, 3 lớp (Setosa, Versicolor, Virginica), 4 thuộc tính.

Biểu đồ	Dùng để	Lưu ý
Scatter plot (và mảng scatter)	Quan hệ giữa hai biến	Có thể mã hóa thêm biến bằng kích thước, hình dạng, màu của điểm.
Histogram	Phân phối một biến	Hình dạng phụ thuộc **số bin**. Làm mượt bằng KDE.
Box plot (Tukey)	So sánh phân phối giữa các nhóm	Bền vững với outlier; là bản đơn giản của PDF/histogram.
2-D histogram	Phân phối đồng thời hai biến	Slide ghi chú matrix plot thường được ưa hơn.
Matrix plot	Vẽ ma trận dữ liệu, ma trận tương quan, ma trận tương đồng/khoảng cách	Chuẩn hóa (z-score) để một thuộc tính không lấn át. Hữu ích khi sắp xếp theo lớp.
Contour plot	Biến liên tục đo trên lưới không gian (nhiệt độ mặt biển, độ cao)	Đường đồng mức nối các điểm cùng giá trị.
Parallel coordinates	Dữ liệu nhiều chiều	Mỗi đối tượng là một đường. **Thứ tự trục ảnh hưởng** khả năng thấy nhóm.
Star plot (radar), Chernoff faces	Mỗi đối tượng thành một glyph	Mỗi đặc trưng ứng với độ dài/kích thước của glyph.

KẾT LUẬN CỦA SLIDE VỀ EDA

- EDA (Tukey) là bước đầu: (1) biết có dữ liệu gì, (2) xem phân phối và quan hệ giữa biến, (3) đánh giá chất lượng. Hiểu dữ liệu là điều kiện để chọn cách chuẩn bị và mô hình.
- Động cơ: giúp chọn công cụ tiền xử lý hoặc phân tích phù hợp, và tận dụng khả năng nhận mẫu hình của con người.

2.5. Độ tương đồng và khác biệt

- **Similarity**: càng giống càng cao, thường trong [0,1]. **Dissimilarity**: càng giống càng thấp, nhỏ nhất thường 0, cận trên tùy trường hợp. **Proximity** là tên chung của cả hai.
- Từ khoảng cách d sang tương đồng s: **s = f(d)**, f là hàm giảm chặt bất kỳ.

Cho thuộc tính đơn

Kiểu	Dissimilarity d	Similarity s
Nominal	0 nếu p = q; 1 nếu khác	1 nếu p = q; 0 nếu khác
Ordinal	$\|p - q\| / (n - 1)$ (giá trị ánh xạ về số nguyên 0..n−1)	$1 - \|p - q\| / (n - 1)$
Interval/Ratio	$\|p - q\|$	−d, hoặc 1/(1+d), hoặc 1 − (d − min_d)/(max_d − min_d)

Cho vector nhiều chiều

Độ đo	Công thức / ý	Khi dùng
Minkowski	$d = (\Sigma \|p_k - q_k\|^r)^{1/r}$	Tổng quát hóa của ba độ đo dưới. Đừng nhầm r với n (số chiều).
Manhattan (L1)	r = 1	Hamming distance là trường hợp trên vector nhị phân.
Euclidean (L2)	r = 2	Thuộc tính định lượng.
Supremum (L∞)	r = ∞: chênh lệch lớn nhất theo một thành phần	
Cosine	cos = (A·B) / (‖A‖ ‖B‖)	So sánh tài liệu qua vector đếm từ; nhìn vào hướng/phân phối từ.
SMC	(f11 + f00) / (f01 + f10 + f11 + f00)	Nhị phân, tính cả khớp 0-0.
Jaccard	f11 / (f01 + f10 + f11)	Nhị phân, **bỏ qua 0-0**; hợp với dữ liệu thưa.
Gower	$\Sigma \delta_k s_k / \Sigma \delta_k$; $\delta_k = 0$ nếu thuộc tính nhị phân bất đối xứng mà cả hai đều 0, hoặc một bên thiếu; ngược lại $\delta_k = 1$	Dữ liệu hỗn hợp kiểu; bỏ qua giá trị thiếu.

KEY POINT

- Khi thang đo các thành phần khác nhau, **phải chuẩn hóa (z-score)** trước khi tính Euclidean/Minkowski, nếu không một biến sẽ chi phối khoảng cách.
- **Metric** thỏa: (1) dương xác định: $d \geq 0$ và $d = 0$ khi và chỉ khi p = q; (2) đối xứng; (3) bất đẳng thức tam giác $d(p,r) \leq d(p,q) + d(q,r)$. Thiếu (3) thì không phải metric. Similarity: $s = 1$ chỉ khi p = q, và đối xứng.

Ví dụ và bài tập trong slide (đã kiểm bằng code)

Ví dụ	Kết quả
p = [1 0 0 0 0 0 0 0 0 0], q = [0 0 0 0 0 0 1 0 0 1]	f01 = 2, f10 = 1, f00 = 7, f11 = 0 → SMC = 0,7; Jaccard = 0
A = [3 2 0 5 0 0 0 2 0 0], B = [1 0 0 0 0 0 0 1 0 2]	A·B = 5; ‖A‖ = √42 ≈ 6,481; ‖B‖ = √6 ≈ 2,449; cosine ≈ 0,315
4 điểm p1(0,2), p2(2,0), p3(3,1), p4(5,1)	L1(p1,p2) = 4; L2(p1,p2) = 2,83; L∞(p1,p2) = 2
Bài tập: A(2,1), B(4,3), C(1,1)	Euclid A–C = 1, A–B = 2,83. Manhattan A–C = 1, A–B = 4. Cosine A–C = 0,949, A–B = 0,984

PHÂN TÍCH CỦA MÌNH (không có trong slide)

- Nhận xét bài tập: theo khoảng cách A gần C hơn B; theo cosine A lại "giống" B hơn một chút vì cosine chỉ xét hướng, không xét độ dài.

⚠ LỖI / ĐIỂM LỆCH TRONG SLIDE

- Ví dụ cosine: slide ghi ‖B‖ = 2,245 nhưng đúng là √6 ≈ 2,449. Kết quả cuối 0,3150 của slide vẫn đúng (tính lại được 0,315). Đây là lỗi đánh máy ở bước trung gian.

2.6. Mật độ và lời nguyền số chiều

- **Mật độ**: xác suất (hàm mật độ xác suất), Euclidean (số điểm trên đơn vị thể tích), dựa trên đồ thị (số cạnh so với đồ thị đầy đủ), mật độ ma trận (tỉ lệ phần tử khác 0).
- **KDE (Kernel Density Estimation)**: ước lượng hàm mật độ **phi tham số**: $\hat{f}_h(x) = (1/nh)\ \Sigma\ K((x - x_i)/h)$. K là kernel (hàm không âm, tích phân bằng 1, thường Gaussian), h > 0 là bandwidth (tham số làm mượt).
- Mật độ Euclidean: **theo ô** (chia lưới đều, đếm điểm mỗi ô) hoặc **theo tâm** (đếm điểm trong bán kính quanh một điểm).
- **Curse of dimensionality**: chiều tăng thì không gian lớn theo hàm mũ; mật độ → 0; mọi điểm có khoảng cách Euclid gần như bằng nhau; khái niệm gần/xa kém ý nghĩa với clustering và phát hiện outlier. Thí nghiệm trong slide: sinh 500 điểm ngẫu nhiên, đo $\log_{10}((\text{max_dist} - \text{min_dist})/\text{min_dist})$ theo số chiều (2 đến 50): đường cong giảm mạnh từ khoảng 3,3 xuống khoảng 0,15 (đọc từ hình).

TỰ KIỂM TRA CỦA BƯỚC NÀY

- **Đối chiếu nguồn:** đã xem ảnh các trang 6, 36, 47, 56 của DL03a và kiểm lại mọi ví dụ số bằng code (cosine, SMC/Jaccard, khoảng cách, bài tập).
- **Ý tác giả và của mình:** định nghĩa, công thức, bảng là của slide. Mẹo interval/ratio, đáp án hai câu hỏi thang đo, nhận xét bài tập là của mình.
- **Lỗi trong slide:** hai điểm ở trên (cosine, bảng ordinal). Ngoài ra slide ghi 'T-SNA' (đúng là t-SNE) và 'Principle' (đúng là Principal).
- **Chắc chắn:** cao cho bảng và công thức. Trung bình cho phần trực quan hóa (các trang 80–96): mình chỉ đọc lớp chữ và chú thích, chưa xem từng hình. Con số 3,3 và 0,15 đọc ước lượng từ đồ thị nên chỉ mang tính minh họa.

BƯỚC 3

Chất lượng dữ liệu và giá trị thiếu

Nguồn: DL03a (chất lượng), DL03c (missing values)

3.1. Ba vấn đề chất lượng (DL03a)

KEY POINT

- Vấn đề: **noise và outlier**, **giá trị thiếu**, **dữ liệu trùng**.
- Phát hiện bằng: **thống kê** và **trực quan hóa**.
- Xử lý cơ bản: **đánh dấu giá trị là thiếu** hoặc **loại đối tượng**.

Vấn đề	Định nghĩa và nguyên nhân	Xử lý
Noise	Sự biến dạng giá trị gốc. Ví dụ: giọng nói méo qua điện thoại kém, 'tuyết' trên màn hình TV, sai số đo.	Tìm dữ liệu ít nhiễu hơn; đôi khi khử nhiễu bằng xử lý tín hiệu.
Outlier	Đối tượng có giá trị đặc trưng khác biệt đáng kể so với đa số. Hai lý do: (1) outlier thật, là đối tượng đặc biệt (ví dụ IQ của thiên tài); (2) lỗi đo.	Phát hiện bằng thống kê, rồi biến giá trị bất thường thành thiếu, hoặc loại cả đối tượng.
Missing	Thông tin không thu thập được (người từ chối khai tuổi, cân nặng); thuộc tính không áp dụng cho mọi trường hợp (thu nhập hàng năm của trẻ em); giá trị sai bị đặt thành thiếu.	Xem 3.2 và 3.3.
Duplicate	Đối tượng trùng hoặc gần trùng (ví dụ cùng người nhiều email). Vấn đề lớn khi gộp dữ liệu từ nhiều nguồn không đồng nhất.	Data cleaning; công cụ ETL thường có sẵn bước khử trùng.

- DL03b bổ sung các biểu hiện của dữ liệu thực tế: **incomplete** (thiếu giá trị), **inconsistent** (ví dụ '03/07/2015' và 'March 07, 2015'), **noisy** (lỗi hoặc outlier, ví dụ gender = Male nhưng pregnant = Yes), **large-scale**, **nhiều kiểu** (số, nominal, văn bản, web, ảnh, âm thanh/video).
- DL03b: rời rạc hóa (binning) giúp làm mượt dữ liệu và xử lý outlier. DL03a: median và IQR là các thống kê bền vững với outlier (xem bước 2).
- DL03c (phần nhận xét về redundancy): nhiều cảm biến nhiễu cùng đo một đại lượng thì nên giữ cả ba để lấy trung bình giảm nhiễu, đừng vội loại vì 'dư thừa'.

3.2. Giá trị thiếu: bốn hướng giải quyết (DL03c)

- Nhiều bộ dữ liệu thực tế có giá trị thiếu, trong khi hầu hết thuật toán đòi hỏi đủ giá trị cho mỗi mẫu huấn luyện.
- Nguyên nhân: chi phí đo cao, cảm biến hỏng, người trả lời ngại trả lời một số câu, khảo sát thiết kế kém.
- Thiếu có thể nằm ở **đặc trưng**, ở **nhãn** (chỉ một lớp, hoặc...?), hoặc cả hai.

Hướng	Cách làm	Ưu/nhược theo slide
1. Loại quan sát	Bỏ các dòng có giá trị thiếu (hoặc dòng tệ nhất)	Lãng phí dữ liệu quý và đắt; nếu mỗi dòng đều thiếu một chút thì mất sạch. Có thể gây thiên lệch nếu thiếu không ngẫu nhiên (3.3).
2. Loại thuộc tính	Bỏ cả cột có thiếu	'Hơi quá tay'.
3. Imputation	Thay bằng giá trị 'giả' ước lượng được	Xem 3.4.
4. Dùng thuật toán chịu được thiếu	Xử lý thiếu ngay trong quá trình học	Xem 3.5.

- DL03a liệt kê tương tự: loại đối tượng, loại thuộc tính, **bỏ qua giá trị thiếu khi phân tích**, ước lượng (imputation, ví dụ thay bằng mean hoặc mean có trọng số theo xác suất của các giá trị khả dĩ).

3.3. Ba cơ chế thiếu: MCAR, MAR, MNAR (DL03c)

KEY POINT

- Câu hỏi then chốt trước khi xử lý: **vì sao giá trị bị thiếu?** Cơ chế thiếu quyết định liệu bỏ dòng thiếu có "ổn" (okay) hay gây thiên lệch.
- Ví dụ trong slide: x là chiều cao, y là khả năng limbo (so với giá trị trung bình); huấn luyện hồi quy dự đoán y từ x. Biến 'recorded?' là việc giá trị có được ghi nhận hay không.

Cơ chế	Tên đầy đủ	Quan hệ của 'recorded?'	Ví dụ slide (limbo)	Ví dụ khảo sát
MCAR	Missing Completely At Random	Không liên kết với x hay y. Như tung đồng xu.	"Bắn súng ngắn vào bảng tính, xóa ngẫu nhiên các ô."	Một nửa phiếu khảo sát bị thất lạc do bọ phá hoại ngẫu nhiên.
MAR	Missing At Random	Phụ thuộc vào biến **quan sát được** (x = chiều cao). Ngẫu nhiên nhưng bị lệch theo chiều cao.	Việc ghi nhận 'ngẫu nhiên nhưng bị lệch theo chiều cao'.	Nam ít điền khảo sát trầm cảm hơn, nhưng sau khi tính đến giới tính thì không liên quan mức độ trầm cảm.
MNAR	Missing Not At Random	Phụ thuộc chính giá trị y (limbo) bị thiếu.	Việc ghi nhận 'ngẫu nhiên nhưng bị lệch theo limbo'.	Người trầm cảm ít điền khảo sát về trầm cảm (tương tự: người vui ít điền khảo sát khiếu nại).

- Slide nhận xét tên MAR rất dễ gây nhầm; tên hợp lý hơn là **"Missing, conditionally at random"** (thiếu ngẫu nhiên có điều kiện), nhưng như vậy sẽ phá viết tắt.
- Slide hỏi "đây là MCAR, MAR hay MNAR?" cho ba ví dụ khảo sát (bọ phá hoại, giới tính nam, người trầm cảm). Slide tự ghi chú ví dụ thứ 3 'maybe, I'm making these up' (giảng viên tự đặt ra).

PHÂN TÍCH CỦA MÌNH (không có trong slide)

- Đáp án mình suy ra: ví dụ 1 = **MCAR**; ví dụ 2 = **MAR** (thiếu phụ thuộc giới tính, là biến quan sát được); ví dụ 3 = **MNAR** (thiếu phụ thuộc chính mức trầm cảm). Hình mô tả quan hệ của slide khớp với cách đọc này nhưng slide không ghi đáp án.
- Hệ quả suy ra từ slide: nếu MNAR, bỏ dòng thiếu hoặc điền bừa sẽ cho kết quả 'thiên lệch (bias, tức sai)'. Slide ghi rõ ở phần 'conclusions': tránh dữ liệu thiếu bằng cách bỏ đi thì không lý tưởng, vì (1) lãng phí dữ liệu, (2) có thể là MNAR nên kết quả bị thiên lệch.

3.4. Imputation (điền giá trị thiếu)

Phương pháp	Cách làm	Ưu	Nhược / lưu ý
Mean / Mode	Mean cho thuộc tính liên tục; mode (giá trị phổ biến nhất) cho phân loại. sklearn: *SimpleImputer*.	Không đổi mean/mode của thuộc tính.	**Dưới-biểu diễn độ biến thiên** của dữ liệu. Slide xếp vào nhóm 'pretty bad imputation'; hình hồi quy Income–Education cho thấy mean substitution làm đường hồi quy phẳng hơn đường của dữ liệu đầy đủ.
Hot deck	Với mỗi bản ghi thiếu, tìm bản ghi **giống nhất** rồi chép giá trị tương ứng.	Giá trị điền thực tế (đã từng xuất hiện).	Slide hỏi 'nhược điểm là gì?' nhưng không trả lời (xem phân tích bên dưới).
Nearest neighbor (k-NN)	Điền dựa trên k láng giềng gần nhất (ví dụ trong slide điền 'Refund').	Dùng cấu trúc gần/xa của dữ liệu.	Phụ thuộc cách đo khoảng cách (chuẩn hóa, độ đo, xem bước 2.5).
Decision rule / cây quyết định	Dùng luật học được (ví dụ Taxable Income > 110 → Yes, ≤ 110 → No) để điền.	Tận dụng quan hệ giữa các thuộc tính.	Luật lấy từ dữ liệu đầy đủ.
Regression	Tách dữ liệu đủ giá trị và có thiếu; dùng phần đủ để ước lượng mô hình hồi quy của thuộc tính theo các thuộc tính khác, rồi dự đoán giá trị thiếu.	Giữ được quan hệ giữa các thuộc tính.	Giả định về dạng mô hình hồi quy.
Multiple imputation	Ý tưởng: tránh thiên lệch do **một** phương pháp imputation, nên thực hiện nhiều lần. Quy trình: dữ liệu thiếu → m bộ dữ liệu được điền (imputation) → phân tích từng bộ → **gộp (pooling)** kết quả cuối phản ánh độ bất định.	Phản ánh độ bất định của ước lượng.	Tốn kém hơn.
MICE (Multivariate Imputation by Chained Equations)	Một dạng multiple imputation, nghe nói hoạt động khá tốt, có trong sklearn. (1) Điền tất cả giá trị thiếu bằng giá trị **ngẫu nhiên** (slide ghi '?!?'). (2) Hồi quy từng thuộc tính có thiếu theo các thuộc tính còn lại, theo chuỗi → 1 bộ dữ liệu đã điền. (3) Lặp lại toàn bộ N lần → N bộ. (4) Lấy trung bình N bộ → bộ cuối cùng.		sklearn *IterativeImputer* thực hiện bước 1 và 2 (một bộ dữ liệu).

⚠ ĐIỂM LỆCH TRONG SLIDE

- Điểm lệch giữa hai slide: slide Multiple Imputation nói **gộp kết quả phân tích** của m bộ (pooling), còn slide MICE (bước 4) nói **lấy trung bình các bộ dữ liệu đã điền**. Hai cách này không giống nhau. Khi trả lời thi, nên nêu theo đúng slide được hỏi và có thể ghi chú sự khác biệt.
- Slide ghi 'impute with Mean ... Doesn't changes the mean' (lỗi ngữ pháp, ý là không làm đổi giá trị trung bình).

PHÂN TÍCH CỦA MÌNH (không có trong slide)

- **Nhược điểm hot deck (slide bỏ ngỏ):** cần định nghĩa độ đo 'giống nhất' (phụ thuộc bước chuẩn hóa); tốn công tính khoảng cách; có thể chép luôn nhiễu hoặc outlier của bản ghi nguồn; chọn một donor duy nhất thì mất đi độ bất định. Đây là suy luận của mình, không phải nội dung slide.
- **Mean/mode với MAR/MNAR:** slide không phân tích riêng. Mình suy ra chỉ khi gần MCAR thì mean imputation mới ít lệch; mức độ này cần kiểm chứng thêm trên dữ liệu cụ thể.
- Slide đưa mean/mode vào cùng nhóm 'Option 3: Imputation' nhưng đánh giá riêng là 'pretty bad'. Nên coi đây là phương án nhanh, không phải phương án tốt.

3.5. Hướng 4: dùng thuật toán chịu được giá trị thiếu

- Giá trị thiếu có thể được tính đến ngay trong quá trình học.
- **Clustering:** độ tương đồng giữa các đối tượng tính chỉ trên các thuộc tính không thiếu (cùng ý tưởng với Gower ở bước 2).

- **Phân loại:** slide liệt kê Gradient Boosting, kNN, Random Forests (kèm 'yay').
- Tài nguyên sklearn trong DL03c: mục 6.4 'Imputation of missing values' gồm univariate vs multivariate (SimpleImputer vs IterativeImputer), nearest neighbors imputation, marking imputed values, và estimators that handle NaN values.

PHÂN TÍCH CỦA MÌNH (không có trong slide)

• Việc một thuật toán cụ thể có nhận NaN hay không **phụ thuộc vào cài đặt trong thư viện**. Mình chưa kiểm chứng từng estimator trong sklearn. Khi làm bài tập thật, hãy đọc mục 'Estimators that handle NaN values' trong tài liệu sklearn mà slide đã dẫn.

3.6. Bảng chọn cách xử lý thiếu

Tình huống	Hướng cân nhắc
Thiếu rất ít, nghi ngờ MCAR	Loại dòng hoặc mean/mode có thể chấp nhận (mình suy ra, mức chắc chắn trung bình)
Một cột thiếu gần hết	Cân nhắc loại cột (Option 2), nhưng slide cảnh báo là 'hơi quá tay'
Muốn giữ quan hệ giữa các biến	Regression/MICE (IterativeImputer), hoặc k-NN/hot deck
Cần phản ánh độ bất định của ước lượng	Multiple imputation
Dùng cây/rừng/boosting	Xem thuật toán có xử lý NaN sẵn không (hướng 4)
Nghi ngờ MNAR	Cơ chế thiếu phụ thuộc chính giá trị thiếu nên mọi cách đều có nguy cơ lệch; slide không đưa giải pháp riêng

TỰ KIỂM TRA CỦA BƯỚC NÀY

• **Đối chiếu nguồn:** DL03a trang 24–26 (chất lượng, thiếu, trùng), DL03c phần missing values (từ 'Missing values' tới 'scikit-learn resources'). Các hình MCAR/MAR/MNAR đọc qua chú thích và sơ đồ chữ trích từ file.
• **Ý tác giả và của mình:** định nghĩa ba cơ chế, bốn hướng, các phương pháp imputation, pros/cons là của slide. Đáp án ba ví dụ khảo sát, nhược điểm hot deck, bảng chọn cách xử lý là của mình (đã gắn nhãn).
• **Bịa đặt:** không thêm công thức hay thuật toán ngoài slide. Với các chỗ slide bỏ ngỏ, mình nói rõ là suy luận.
• **Thiên kiến:** mình tránh khuyên 'nên dùng phương pháp X' vì slide không xếp hạng đầy đủ; bảng 3.6 chỉ là gợi ý, không phải kết luận của giảng viên.
• **Chắc chắn:** cao cho định nghĩa và bốn hướng. Trung bình cho nội dung diễn giải hình MCAR/MAR/MNAR (không xem được ảnh gốc DL03c, chỉ có chữ và sơ đồ).

BƯỚC 4

Chia dữ liệu và chọn mẫu

Nguồn: DL03b (leakage, split, k-fold), DL03a (sampling)

4.1. Data leakage

KEY POINT

- **Cách áp dụng kỹ thuật chuẩn bị dữ liệu rất quan trọng.** Vấn đề của chuẩn bị dữ liệu 'ngây thơ' là **data leakage**.
- Thông tin về tập giữ lại (holdout, ví dụ tập test) **rò rỉ** vào dữ liệu huấn luyện → ước lượng hiệu năng dự đoán của mô hình **sai**.
- Đúng: **Data Splitting → Data Preparation → Modelling**. Sai: Data Preparation → Data Splitting → Modelling.

PHÂN TÍCH CỦA MÌNH (không có trong slide)

- Slide chỉ nói nguyên tắc chung. **Mình suy ra** rằng mọi phép có 'học' từ dữ liệu (tính mean/std cho chuẩn hóa, min/max, điền giá trị thiếu, chọn đặc trưng, PCA...) nên được **fit chỉ trên tập train** rồi mới áp dụng lên tập test. Ví dụ code minh họa ở bước 7.
- Khi dùng k-fold CV, nguyên tắc tương tự áp dụng trong từng fold. Slide không nêu chi tiết này, nên đây là phần suy luận của mình.

4.2. Tập train, test, validation

Tập	Vai trò	Ghi chú từ slide
Training	Học/huấn luyện mô hình	
Test	Đo hiệu năng của mô hình	Tỉ lệ train–test ví dụ: 50%–50%; 2/3–1/3; 70%–30%.
Validation	**Theo dõi** quá trình huấn luyện	Khác tập test. Ví dụ chia train–test–validation: 1/3 – 1/3 – 1/3.

- Cả train và test đều phải **đại diện** cho dữ liệu gốc.
- **Generalisation so với overfitting:** đường cong 'just right' khớp xu hướng; đường 'overfitting' bám sát từng điểm nhiễu.
- Biểu đồ lỗi theo thời gian huấn luyện (slide): lỗi train giảm liên tục; lỗi validation giảm rồi **tăng trở lại** → dấu hiệu overfitting.

PHÂN TÍCH CỦA MÌNH (không có trong slide)

- Điểm lỗi validation bắt đầu tăng chính là chỗ nên dừng huấn luyện (early stopping). Slide có biểu đồ nhưng không nêu tên early stopping; đây là cách diễn giải của mình.

4.3. K-fold cross validation

KEY POINT

- Dùng khi chỉ có **ít** mẫu.
- Các bước: chia toàn bộ dữ liệu thành K fold kích thước bằng nhau → dùng 1 fold làm test, (K−1) fold còn lại làm train → lặp K lần để mỗi fold được làm test một lần → **lấy trung bình** K kết quả (ví dụ tỉ lệ lỗi).

Ví dụ 5-fold	Lần 1	Lần 2	Lần 3	Lần 4	Lần 5
Fold 1	Train	Train	Train	Train	**Test**
Fold 2	Train	Train	Train	**Test**	Train
Fold 3	Train	Train	**Test**	Train	Train
Fold 4	Train	**Test**	Train	Train	Train
Fold 5	**Test**	Train	Train	Train	Train

PHÂN TÍCH CỦA MÌNH (không có trong slide)

- Slide có dòng 'Leave-one-out cross validation:' nhưng để trống nội dung. Hiểu theo thông lệ: LOO là trường hợp K bằng số mẫu (mỗi lần chỉ giữ 1 mẫu làm test). Đây là kiến thức ngoài slide, mức chắc chắn cao nhưng không được slide xác nhận.

4.4. Sampling (chọn mẫu) (DL03a)

- Sampling là kỹ thuật chính để **chọn dữ liệu**, dùng cho cả khảo sát ban đầu và phân tích cuối. Nhà thống kê lấy mẫu vì thu cả tập quá đắt hoặc tốn thời gian; trong khai phá dữ liệu vì xử lý cả tập quá tốn kém (không vừa bộ nhớ, quá chậm).
- **Nguyên tắc cốt lõi:** dùng mẫu sẽ hiệu quả gần như dùng cả tập **nếu mẫu đại diện**. Mẫu đại diện nếu có xấp xỉ các tính chất quan tâm của tập gốc.

Phân loại	Kiểu	Ý nghĩa
Có hoàn lại?	Without replacement	Chọn xong thì bỏ khỏi quần thể.
	With replacement	Không bỏ khỏi quần thể, cùng một đối tượng có thể được chọn nhiều lần.
Cách chọn	Simple random	Xác suất chọn mỗi phần tử bằng nhau.
	Stratified	Chia dữ liệu thành các phân vùng rồi lấy mẫu ngẫu nhiên từ mỗi phân vùng.

- **Kích thước mẫu:** hình minh họa 8000, 2000, 500 điểm (cấu trúc mờ dần khi mẫu nhỏ). Câu hỏi slide: cỡ mẫu cần thiết để có ít nhất một đối tượng từ mỗi nhóm trong 10 nhóm (slide không ghi đáp án).
- Xác định cỡ mẫu: **thống kê** dùng khoảng tin cậy hoặc lực kiểm định mong muốn; **machine learning** thường 'nhiều hơn thì tốt hơn', kiểm tra bằng độ chính xác kiểm chứng chéo.

PHÂN TÍCH CỦA MÌNH (không có trong slide)

- Liên hệ: khi cần train/test đều 'đại diện' (4.2), có thể dùng lấy mẫu phân tầng để giữ tỉ lệ các lớp. Đây là suy luận của mình, slide không nối trực tiếp hai ý này.
- Câu hỏi về 10 nhóm: nếu mẫu quá nhỏ, nhóm hiếm có thể không xuất hiện. Slide chỉ đặt vấn đề, không đưa công thức.

TỰ KIỂM TRA CỦA BƯỚC NÀY

- **Đối chiếu nguồn:** DL03b trang 6–9 (leakage, train/test/validation, k-fold, ví dụ 5-fold), DL03a trang 31–35 (sampling, đã xem hình sample size).
- **Ý tác giả và của mình:** nguyên tắc leakage, tỉ lệ chia, các bước k-fold, phân loại sampling là của slide. Việc mở rộng leakage sang imputation/scaling/chọn đặc trưng, early stopping, định nghĩa LOO là của mình (đã gắn nhãn).
- **Bịa đặt/thiên kiến:** không đưa tỉ lệ chia nào ngoài các tỉ lệ slide nêu. Mình tránh khuyên 'dùng bao nhiêu fold' vì slide không nói.
- **Chắc chắn:** cao cho nội dung của slide; trung bình cho các phần suy luận. Chưa xác minh: hình đường cong lỗi train/validation chỉ đọc qua chú thích 'train', 'validation', 'error', 'time'.

BƯỚC 5

Biến đổi biểu diễn

Mã hóa · chuẩn hóa · rời rạc hóa · aggregation · phép biến đổi khác

5.1. Bốn kiểu thay đổi đặc trưng (DL03c)

Kiểu	Mô tả	Ví dụ	Ý nghĩa
One-to-one	Một đặc trưng → một đặc trưng đã biến đổi	clipping, normalization, discretization, log(x), 1/x, exp(x)...	Đưa đặc trưng gốc vào khoảng giá trị hữu ích hơn cho bộ học.
One-to-many	Một đặc trưng → nhiều đặc trưng	One-hot: cat → (0,1,0,0) với {dog, cat, cow, eel}; polynomial expansion: x → (x, x^2, x^3, x^4)	Giúp bộ học làm việc dễ và tự nhiên hơn.
Many-to-one (feature construction)	Nhiều đặc trưng → một đặc trưng mới	(x1 and x2) or x3; (x1 + x2) × x3	Nắm bắt **quan hệ** giữa các đặc trưng cơ bản; bổ sung vào không gian đặc trưng.
Many-to-many	Nhiều → nhiều	Tích Descartes (cartesian product): one-hot trên (dog, ♀), (dog, ♂), (cat, ♀), (cat, ♂); PCA, kernel PCA, ICA; one-hot từ clustering	Cartesian product cho phép bộ học 'intersectional'; PCA... gom thông tin dư thừa. Hỏi thêm: giữ hay bỏ các đặc trưng gốc?

5.2. Mã hóa biến phân loại (DL03b)

- Biến phân loại chứa nhãn thay vì số; nhiều thuật toán cần số.
- **One-hot encoding**: mỗi giá trị duy nhất trong cột phân loại thành một cột mới (dummy variables). Ví dụ Country ∈ {USA, UK, France} → 3 cột USA, UK, France.
- **Dummy encoding**: **N − 1** cột cho N giá trị duy nhất (bỏ một cột; ví dụ chỉ giữ UK và France, dòng USA là (0,0)).
- **Ordinal encoding**: dữ liệu **có thứ tự tự nhiên** (Poor, Good, Very Good, Excellent; cỡ áo XS–XL) → gán số nguyên theo thứ tự (1, 2, 3, 4).

CÂU HỎI MỞ CỦA SLIDE

- Câu hỏi của DL03c: nếu x ∈ {dog, cat, ferret} mà mã hóa dog → 1, cat → 2, ferret → 3 thì **không phải ý hay**. Vì sao? Slide để ngỏ.

PHÂN TÍCH CỦA MÌNH (không có trong slide)

- Đáp án mình suy ra: cách này áp một **thứ tự và khoảng cách giả** lên dữ liệu nominal (ferret 'lớn hơn' dog; khoảng cách dog–ferret gấp đôi dog–cat), trong khi các loài không có thứ tự. Với dữ liệu nominal nên dùng one-hot/dummy; chỉ dùng ordinal encoding khi dữ liệu thực sự có thứ tự (như slide DL03b nói).

5.3. Chuẩn hóa và đưa về cùng thang (normalisation/scaling)

- Vấn đề: dữ liệu số có các đặc trưng ở các khoảng khác nhau (ví dụ tập bệnh tiểu đường: tuổi, BMI, huyết áp, insulin huyết thanh... có thang rất khác nhau).
- Một số phương pháp, như **KNN, SVM, gradient descent**, bị ảnh hưởng mạnh bởi thang của dữ liệu.
- Một dạng phổ biến: đưa mọi đặc trưng về một khoảng cố định, ví dụ [0, 1].

Phương pháp	Công thức	Kết quả	sklearn
Min-Max (đưa về [0,1])	$x' = (x - x_{min}) / (x_{max} - x_{min})$	Min thành 0, max thành 1	MinMaxScaler
Min-Max về [New_{min}, New_{max}]	$x' = (x - x_{min})/(x_{max} - x_{min}) \cdot (New_{max} - New_{min}) + New_{min}$	Khoảng tùy chọn	MinMaxScaler

Phương pháp	Công thức	Kết quả	sklearn
Z-score (standardisation, center scaling)	$z = (x - \mu) / \sigma$	Trung bình 0, độ lệch chuẩn 1; có giá trị âm và dương; DL03a: dữ liệu rơi xấp xỉ trong [−3, 3]	StandardScaler

Chọn normalisation hay standardisation? (quy tắc kinh nghiệm của slide DL03b)

- Standardisation cho giá trị dương và âm quanh 0. Normalisation đưa các biến về cùng khoảng.
- Nếu phân phối **chuẩn** → standardise; nếu không → normalise. **Còn nghi ngờ → normalise.**
- Có thể kết hợp: standardise rồi normalise.

PHÂN TÍCH CỦA MÌNH (không có trong slide)

- Đây là quy tắc kinh nghiệm của giảng viên, không phải định lý; trong thực hành còn tùy thuật toán.
- Từ công thức, min-max phụ thuộc trực tiếp vào x_{min} và x_{max}, nên một outlier cực đoan sẽ kéo giãn khoảng và nén phần lớn dữ liệu vào một đoạn hẹp (mình suy ra từ công thức, slide không nêu).
- Theo nguyên tắc leakage (bước 4): tính μ, σ, min, max trên **tập train** rồi áp lên test.

Các hàm biến đổi đơn giản (DL03a)

- Một phép biến đổi thuộc tính ánh xạ mọi giá trị cũ sang giá trị mới sao cho mỗi giá trị cũ ứng với một giá trị mới: x^k, log(x), e^x, |x|, cùng chuẩn hóa/standardization.

5.4. Rời rạc hóa (discretisation/binning)

KEY POINT

- Chuyển giá trị số liên tục (giá, tuổi, cân nặng) thành các khoảng rời rạc.
- Lý do: một số thuật toán yêu cầu hoặc ưa đầu vào phân loại (cây quyết định, thuật toán dựa trên luật); **làm mượt dữ liệu, xử lý outlier**.
- Hai loại: **unsupervised** (không dựa vào nhãn lớp) và **supervised** (dựa vào nhãn lớp). Công cụ: KBinsDiscretizer (sklearn).

Phương pháp	Cách làm	Tham số sklearn (theo slide)
Equal-width (uniform)	Tìm Max và Min; chia [Min, Max] thành N khoảng bằng nhau; độ rộng W = (Max − Min)/N	strategy='uniform'
Equal-depth (frequency/quantile)	Chia thành N khoảng sao cho mỗi khoảng có **xấp xỉ cùng số mẫu**	strategy='quantile'
K-means	Phân cụm một chiều; các giá trị trong mỗi bin có cùng tâm cụm gần nhất; k-means tìm được số lượng và ranh giới khoảng	strategy='kmeans'
1R (supervised)	Tìm điểm chia để rời rạc hóa. Với mỗi điểm chia: đếm tần suất mỗi lớp trong từng nhóm; gán lớp phổ biến nhất cho nhóm; tính lỗi trên mọi nhóm. Điểm chia tốt nhất là điểm có lỗi nhỏ nhất.	R package dprep, hàm disc.1r
Entropy-based (supervised)	Entropy đo độ tạp/bất định của nhóm mẫu: $E(S) = -\Sigma\, p_c \log_2(p_c)$. Đệ quy tìm ranh giới T làm cực tiểu **net entropy** $NE(S,T) = (\|S_1\|/\|S\|)\, E(S_1) + (\|S_2\|/\|S\|)\, E(S_2)$. Nhóm càng thuần thì entropy càng thấp (nhóm thuần = entropy 0).	R package dprep, hàm disc.mentr

Ví dụ trong slide (14 giá trị nhiệt độ, đã kiểm lại bằng code)

Dữ liệu: 85, 80, 83, 70, 64, 65, 68, 71, 69, 72, 75, 75, 81, 72. Sắp xếp: 64, 65, 68, 69, 70, 71, 72, 72, 75, 75, 80, 81, 83, 85.

Phương pháp	Tham số	Kết quả (số mẫu mỗi khoảng)
Equal-width	N = 7, W = (85 − 64)/7 = 3	[64,67): 2 · [67,70): 2 · [70,73): 4 · [73,76): 2 · [76,79): 0 · [79,82): 2 · [82,85]: 2
Equal-depth	N = 4	[64,69]: 4 · [70,72]: 4 · [73,81]: 4 · [83,85]: 2

Phương pháp	Tham số	Kết quả (số mẫu mỗi khoảng)
K-means	N = 3	Hình slide: cụm {64, 65, 68}, {69, 70, 71, 72, 75}, {80, 81, 83, 85}

⚠ LƯU Ý VỀ TÊN THAM SỐ

- Trong slide, tham số viết là **n_bin** (ví dụ KBinsDiscretizer(n_bin=7,...)). Theo hiểu biết của mình tên tham số thật trong sklearn là **n_bins** (mình chưa kiểm chứng trong tài liệu của sklearn ở phiên làm việc này). Khi viết code hãy kiểm tra lại documentation.

PHÂN TÍCH CỦA MÌNH (không có trong slide)

- Equal-width đơn giản nhưng có thể sinh khoảng rỗng (ví dụ [76,79) ở trên); equal-depth cân bằng số mẫu nhưng độ rộng khoảng không đều (ví dụ [73,81] rộng hơn [70,72]). Đây là nhận xét rút từ chính ví dụ số của slide.

5.5. Aggregation và ánh xạ sang không gian mới (DL03a)

- **Aggregation:** kết hợp hai hay nhiều thuộc tính (hoặc đối tượng) thành một. Mục đích: **giảm dữ liệu**; **đổi thang** (thành phố → vùng → bang → quốc gia); dữ liệu **ổn định hơn** (dữ liệu gộp ít biến thiên hơn, ví dụ giảm tính mùa vụ khi gộp theo năm).
- Ví dụ trong slide: độ lệch chuẩn lượng mưa trung bình **theo tháng** lớn hơn hẳn so với độ lệch chuẩn lượng mưa trung bình **theo năm** trên các điểm đất liền ở Úc (histogram: theo tháng trải rộng tới khoảng 17, theo năm hầu hết dưới khoảng 4).
- **Mapping data to new space**: ví dụ biến đổi Fourier/Wavelet; tín hiệu hai sóng sin cộng nhiễu trong miền thời gian khó thấy, sang miền tần số thì thấy rõ các đỉnh tần số.
- Rời rạc hóa không giám sát (equal width, equal frequency, k-means) cũng được slide xếp trong nhóm này.

PHÂN TÍCH CỦA MÌNH (không có trong slide)

- Slide DL03a liệt kê 'Binarization' trong tiêu đề phần tiền xử lý nhưng không có slide riêng giải thích; mình không bổ sung nội dung.

TỰ KIỂM TRA CỦA BƯỚC NÀY

- **Đối chiếu nguồn:** DL03b trang 10–22; DL03c phần 'changes to features' và 'one-to-one/one-to-many'; DL03a trang 29–30, 42–44. Ví dụ equal-width và equal-depth đã kiểm bằng code, khớp slide.
- **Ý tác giả và của mình:** định nghĩa, công thức, quy tắc chọn normalise/standardise là của slide (quy tắc kinh nghiệm). Đáp án câu hỏi dog/cat/ferret, nhận xét về outlier với min-max, nhận xét ưu nhược equal-width/depth là của mình.
- **Lỗi trong slide:** n_bin (nên là n_bins theo hiểu biết của mình, chưa kiểm chứng). Slide ghi 'Nomalisation', 'Categorial' (lỗi chính tả).
- **Chắc chắn:** cao cho công thức và ví dụ số. Chưa xác minh: kết quả cụm k-means trong ví dụ nhiệt độ (đọc từ hình), chi tiết hình histogram theo tháng/năm (đọc ước lượng).

BƯỚC 6

Thao tác đặc trưng

Construction · extraction · selection

6.1. Vì sao cần thao tác đặc trưng?

- Dữ liệu thô chứa hỗn hợp đặc trưng, không phải đặc trưng nào cũng hữu ích để tạo mô hình.
- Mục tiêu: chọn tập con tối ưu theo một tiêu chí; **giảm chiều và nhiễu**; **trực quan hóa** dữ liệu để chọn mô hình; **cải thiện hiệu năng** (tốc độ, sức mạnh dự đoán, độ đơn giản, khả năng diễn giải).
- Ví dụ trong DL03b: tập nấm 22 thuộc tính (cap-shape, odor, gill-size, ...), nhiệm vụ phân loại ăn được hay độc.

'More features = good?' (DL03c)

- Hình tập Wine (13 đặc trưng, 178 mẫu, 3 lớp, trích từ luận án của Andrew Lensen, VUW, 2019) được chiếu lên 3, 2, 1 đặc trưng (f10, f6, f12) để hỏi: nhiều đặc trưng hơn có luôn tốt hơn không? Slide để mở câu trả lời; ý chính là **không tự động tốt hơn**.
- **Curse of dimensionality** (DL03a, xem bước 2.6): số chiều tăng thì dữ liệu thưa, khoảng cách mất ý nghĩa.
- Bảng 'imaginary example' (DL03c, 1000 ca, nửa nam nửa nữ, 30% bị bệnh tim): cho thấy việc thêm biến sinh ra luật giả và dư thừa.

Luật	fr	φ	Nhãn trong slide	Diễn giải (mình)
smoking → heart disease	120	0,400	simple dependency	0,4 > nền 0,3: có phụ thuộc
sports → ¬heart disease	400	0,800	simple dependency	0,8 > nền 0,7
coffee → ¬heart disease	240	0,700	independency	bằng nền 0,7 nên độc lập
stress → heart disease	150	0,300	independency	bằng nền 0,3
pine bark extract → ¬heart disease	1	1,000	spurious (too few)	φ = 1 nhưng chỉ 1 mẫu
female → ¬heart disease	352	0,704	spurious (too small)	0,704 gần nền 0,7, chênh quá nhỏ
female, stress → heart disease	100	0,385	non-monotonicity	stress đơn 0,3, thêm 'female' đổi tỉ lệ không đơn điệu
stress, smoking → heart disease	100	0,500		
smoking, coffee → heart disease	96	0,400	superfluous variables (dòng 9–11)	coffee không thêm thông tin so với smoking (0,4)
smoking, sports → heart disease	20	0,333	superfluous	
female, sports → ¬heart disease	203	0,808	superfluous	0,808 xấp xỉ sports đơn 0,8

fr = tần suất của vế trái (antecedent) trên toàn bộ; φ = tỉ lệ ca mà vế phải đúng. Nguồn bảng: Webb, tutorial on statistically sound pattern discovery (theo URL trong slide).

PHÂN TÍCH CỦA MÌNH (không có trong slide)

- Cột 'Diễn giải' là phân tích của mình, so φ với tỉ lệ nền (30% bị bệnh tim, tức 70% không bị). Ví dụ này minh họa vấn đề **luật giả (spurious)** và **biến dư thừa (superfluous)** khi xét nhiều biến, là động cơ cho việc đánh giá, chọn đặc trưng. Slide chỉ gắn nhãn, không giải thích chi tiết.
- Vị trí dấu ngoặc 'superfluous variables' trong slide bao các dòng 9, 10, 11 theo hình; mình đọc từ hình bố cục nên có thể lệch một dòng.

6.2. Feature construction (many-to-one)

KEY POINT

- Kết hợp các đặc trưng cơ bản để tạo đặc trưng mới nắm bắt **quan hệ**; **tăng chiều** không gian đặc trưng.
- Ví dụ với [X1, X2, X3]: tuyến tính Xc = X1 + X2 hoặc Xc = 4X1 + 3X2 + 6X3; phi tuyến Xc = X1 × X2.
- **Chất lượng đặc trưng xây dựng ảnh hưởng lớn tới hiệu năng.** (−) tương tác đặc trưng gây lỗi và tăng độ phức tạp; (+) đặc trưng có ý nghĩa hơn dẫn tới mô hình **gọn và chính xác hơn**.

Ví dụ minh họa F3 = F1 × F2

- Hình bên trái: dữ liệu theo (F1, F2) có hai lớp nằm ở các góc phần tư đối diện nhau (lớp xanh ở trên-phải và dưới-trái, lớp đỏ ở trên-trái và dưới-phải), **không thể ngăn cách bằng một đường thẳng**.
- Hình bên phải: sau khi thêm F3 = F1 × F2, dùng (F1, F1×F2) thì **ranh giới quyết định** là đường nằm ngang F1×F2 = 0, tách hai lớp.
- Bài học: một đặc trưng phi tuyến thích hợp làm bài toán trở nên tách tuyến tính.

Hệ thống xây dựng đặc trưng tự động và toán tử

- Cần hai thành phần: **chiến lược tìm kiếm** trong không gian các hàm của đặc trưng gốc, và **cơ chế đánh giá** độ tốt của hàm ứng viên.

Kiểu đặc trưng	Toán tử	Ví dụ
Boolean	Toán tử logic: phủ định, hội, tuyển...	x3 ← not(x1); x4 ← xor(x1, x2)
Nominal/Categorical	Cartesian product	x1 ∈ {dog, cat}, x2 ∈ {rain, snow} → x3 ∈ {(dog,rain), (dog,snow), (cat,rain), (cat,snow)}
Numerical	Cộng, nhân, max, trung bình, bằng nhau...	x1 ∈ ints, x2 ∈ reals; ví dụ x4 ← min(x1, mean(x2, x3))

PHÂN TÍCH CỦA MÌNH (không có trong slide)

- Ví dụ x4 ← min(x1, mean(x2, x3)) trong slide nằm ở vị trí khó phân biệt giữa cột nominal và numerical do bố cục; mình xếp vào numerical vì dùng min/mean.

Genetic Programming (GP) để tạo đặc trưng tự động

- GP là cách **linh hoạt** tạo hàm toán học và logic, biểu diễn dạng cây (ví dụ cây (F1 + F6) / ((F2 × F7) − F2)).
- **Cảnh báo:** không gian tìm kiếm các hàm có ít thông tin cấu trúc (topological). Khả thi, nhưng phải sẵn sàng tốn nhiều thời gian tính toán thử các 'cây vô dụng' (dud trees).
- Quan điểm của giảng viên (DL03c): chỉ tiến hóa ra các câu trả lời tốt cho bài toán cụ thể thì **không phải công thức cho sự thấu hiểu**; thấu hiểu đến từ việc có lý thuyết về thế giới (a.k.a. 'a model') và kiểm tra nó.

Đánh giá đặc trưng mới

- Không phải đặc trưng xây dựng nào cũng tốt; áp dụng các kỹ thuật chọn đặc trưng thông thường để loại các đặc trưng **dư thừa và không liên quan**.
- Lưu ý (DL03c): đặc trưng 'dư thừa' không nhất thiết phải loại. Ví dụ ba cảm biến nhiễu cùng đo một đại lượng: giữ cả ba để lấy trung bình sẽ tốt hơn loại hai cái.

6.3. Feature extraction (giảm chiều bằng biến đổi)

KEY POINT

- Biến đổi vector đặc trưng gốc để giảm chiều từ d xuống m, thường m < d; m đặc trưng mới giữ phần lớn thông tin.
- **Cái giá:** mất danh tính từng đặc trưng; đặc trưng trích xuất **không diễn giải được** bởi con người.
- Dùng cho: nén dữ liệu, giảm nhiễu, cải thiện mô hình, giảm overfitting, trực quan hóa.
- Hai hướng: **projection** (chiếu xuống không gian chiều thấp, giữ khoảng cách) và **manifold learning** (mô hình hóa đa tạp mà dữ liệu huấn luyện nằm trên đó).

Kỹ thuật	Loại	Ý tưởng	Chi tiết cần nhớ
PCA (Principal Components Analysis)	Tuyến tính, không giám sát	Tìm phép chiếu (trục mới) giữ **lượng biến thiên lớn nhất** của dữ liệu; các thành phần chính không tương quan.	Làm bằng vector riêng của ma trận hiệp phương sai hoặc SVD. Mục tiêu: ánh xạ điểm xuống chiều thấp mà giữ thông tin khoảng cách.
ICA (Independent Components Analysis; Blind Source Separation; 'cocktail party problem')	Tuyến tính, không giám sát	Giả định dữ liệu quan sát là tổ hợp tuyến tính của các thành phần **độc lập** chưa biết; tìm phép biến đổi tuyến tính để **khôi phục** các thành phần đó, độc lập thống kê nhất có thể.	PCA và ICA đều tạo thành phần là tổ hợp tuyến tính của biến gốc. PCA loại tương quan nhưng thường **không** tìm ra các thành phần độc lập thật sự nằm dưới dữ liệu.
LDA (Linear Discriminant Analysis)	Tuyến tính, **có giám sát**	Cực đại khoảng cách giữa các trung bình lớp và cực tiểu độ trải trong từng lớp.	sklearn.discriminant_analysis.LinearDiscriminantAnalysis
Kernel PCA	Phi tuyến	Kết hợp cách nhìn toán học cụ thể của PCA với hàm kernel; thực hiện PCA trên dữ liệu như đã được chuyển sang không gian chiều cao: 'blessing of dimensionality'.	Ví dụ slide: hai vòng tròn đồng tâm; PCA không tách được, kernel PCA tách được.
Autoencoder	Phi tuyến (mạng nơ-ron)	Mạng huấn luyện để 'ép' dữ liệu qua **bottleneck layer** ít nơ-ron; gồm encoder, latent space, decoder; đầu ra là dữ liệu tái tạo.	Latent space thường gọi là 'không gian ẩn'.
t-SNE	Phi tuyến	T-distributed Stochastic Neighbor Embedding, dùng trực quan hóa dữ liệu nhiều chiều.	(DL03a, DL03b chỉ nêu ngắn)
ISOMAP	Phi tuyến (manifold)	'Mở cuộn bánh swiss roll': dùng khoảng cách trắc địa (geodesic) dọc bề mặt, không dùng Euclid. 3 bước: (1) xây đồ thị láng giềng (k-NN hoặc trong một bán kính); (2) tính khoảng cách đường đi ngắn nhất = geodesic cho mọi cặp; (3) tạo embedding chiều thấp bằng MDS.	

- **Low-dimensional embedding:** biểu diễn đối tượng từ không gian đặc trưng này sang không gian khác bằng ánh xạ f: X → Y; PCA là ví dụ (Y là không gian các thành phần chính). Các embedding khác: t-SNE, autoencoder, word embedding (Word2vec, GloVe, BERT), trong đó khoảng cách có ý nghĩa.
- Câu hỏi mở của slide: **vì sao tìm thành phần thực sự độc lập là tốt?** (không có đáp án trong slide).

PHÂN TÍCH CỦA MÌNH (không có trong slide)

- Gợi ý cho câu hỏi ICA: nếu dữ liệu thực sự là hỗn hợp các nguồn độc lập (như nhiều người nói cùng lúc trong 'cocktail party'), việc khôi phục đúng các nguồn cho phép tách và diễn giải từng nguồn, trong khi PCA chỉ khử tương quan. Đây là suy luận của mình từ hình và tên gọi trong slide.
- Kernel PCA, ISOMAP, t-SNE: mình xếp là không giám sát theo cách dùng thông thường, nhưng slide chỉ phân loại rõ PCA, ICA, autoencoder (không giám sát) và LDA (có giám sát). Phần xếp loại thêm là suy luận của mình.

6.4. Feature selection (chọn đặc trưng)

KEY POINT

- Giảm số biến đầu vào xuống những biến được cho là hữu ích nhất, loại đặc trưng **không mang thông tin hoặc dư thừa**. Hữu ích với dữ liệu nhiều chiều (DNA hệ gen, văn bản).
- **Dư thừa (redundant)**: trùng thông tin giữa các đặc trưng tương quan (ví dụ giá mua và thuế bán hàng). **Không liên quan (irrelevant)**: không có thông tin cho nhiệm vụ (ví dụ mã sinh viên khi dự đoán GPA).

Hai cách phân loại phương pháp

Cách phân loại	Nhóm	Đặc điểm
Theo số biến xét cùng lúc	**Univariate**	Xét từng đặc trưng độc lập với các đặc trưng khác.
	Multivariate	Xét mọi đặc trưng đồng thời.
Theo quan hệ với bộ phân loại	**Filter**	Chọn tập đặc trưng **trước** khi xây mô hình phân loại.
	Wrapper	Dùng một bộ phân loại để chọn tập con (như hộp đen, thường tìm kiếm tham lam).
	Embedded	Chọn đặc trưng **cùng lúc** với quá trình xây dựng mô hình (ví dụ hồi quy, cây quyết định).
	Brute-force (DL03a)	Thử mọi tập con có thể và chọn tập tốt nhất.

Univariate: đo tương quan với biến mục tiêu

Các phương pháp univariate đo **một loại tương quan** giữa mỗi đặc trưng đầu vào và biến mục tiêu/nhãn lớp. Tương quan dương: hai biến cùng chiều; âm: ngược chiều; không tương quan: không có xu hướng.

Độ đo	Dùng cho	Chi tiết	sklearn/scipy
Pearson r	Hai biến liên tục	$r = \text{cov}(x,y)/(s_x s_y) = \Sigma(x_i - \bar{x})(y_i - \bar{y}) / ((n-1)\, s_x\, s_y)$. Đo tương quan **tuyến tính**, trong $[-1, 1]$.	r_regression
Chi-square χ^2	Dữ liệu rời rạc	$\chi^2 = \Sigma\ (\text{Observed} - \text{Expected})^2 / \text{Expected}$. Kiểm tra tần suất quan sát có khớp tần suất kỳ vọng không. Expected $e_{ij} = \text{Count}(A=a_i) \times \text{Count}(B=b_j) / n$. χ^2 càng lớn thì hai biến càng có khả năng liên quan.	chi2
Mutual information	Đo mức giảm bất định	$I(X;Y)$ đo thông tin chung giữa X và Y, đo sự phụ thuộc lẫn nhau.	mutual_info_classif, mutual_info_regression
Spearman	Biến liên tục	Tương quan phi tuyến (theo slide).	scipy.stats.spearmanr
ANOVA (F-score)	Đặc trưng liên tục, nhãn rời rạc		f_classif

Ví dụ chi-square trong slide

Giới tính \ có ô	Yes	No	Tổng
female	5	7	12
male	5	5	10
Tổng	10	12	22

Slide tính: o(female, yes) = 5; e(female, yes) = 12 × 10 / 22 ≈ 5,455.

PHÂN TÍCH CỦA MÌNH (không có trong slide)

- Mình tính tiếp cho đủ bốn ô: e(female,no) = 6,545; e(male,yes) = 4,545; e(male,no) = 5,455. χ^2 = 0,0379 + 0,0316 + 0,0455 + 0,0379 ≈ **0,153** (đã kiểm bằng code). Giá trị rất nhỏ nghĩa là giới tính và việc mang ô gần như độc lập trong dữ liệu mẫu này. Slide không tính kết quả cuối; đây là phần mở rộng của mình.
- Slide mô tả Spearman là 'tương quan phi tuyến'. Theo DL03a (bước 2), Spearman là Pearson trên hạng, đo quan hệ **đơn điệu** chứ không phải mọi quan hệ phi tuyến. Nên hiểu cho chặt hơn.

Chọn độ đo theo kiểu biến (sơ đồ tổng kết DL03b)

Biến vào	Biến ra: số	Biến ra: phân loại
Số (numerical)	Pearson, Spearman	ANOVA, Kendall
Phân loại (categorical)	ANOVA, Kendall	Chi-squared, Mutual information

Bảng trên đọc từ chữ trong sơ đồ tổng kết; mình chưa xem được các mũi tên nối nên mức chắc chắn trung bình. Cách phân loại này khớp với phần 'Some other measures' ở trên (ANOVA cho đặc trưng liên tục + nhãn rời rạc).

Feature importance (chọn đặc trưng dựa trên độ quan trọng)

- **Feature importance**: điểm số gán cho đặc trưng đầu vào cho biết độ quan trọng tương đối; nêu bật đặc trưng liên quan nhất tới mục tiêu. Có thể đưa vào mô hình wrapper hoặc dùng với **recursive feature elimination**. sklearn: SelectFromModel, RFE.
- Cách tính: **permutation testing**; **hệ số mô hình (tuyến tính)** (ví dụ chạy hồi quy logistic vài lần, lấy trung bình hệ số); **từ cây quyết định**: dựa trên mức giảm tiêu chí (Gini hoặc entropy) dùng để chọn điểm tách (DecisionTreeRegressor.feature_importances_).

Hạn chế của univariate (DL03b)

- Không rõ trước được chọn đặc trưng có hiệu quả không. Cách duy nhất là thử, nhưng với dữ liệu nhiều chiều (ít nhất nửa triệu đặc trưng) thì **thường có ích** (nhận định của slide).
- Chọn bao nhiêu đặc trưng? → dùng **cross-validation**.
- **Không xét tương tác giữa các đặc trưng.** Hình 'Variable Selection': hai đặc trưng riêng lẻ 'sai' có thể tách tốt lớp khi đi cùng nhau (so sánh trường hợp Wrong và Right với SVM).

Multivariate: tìm tập con đặc trưng

- Không gian tìm kiếm là các tập con; số tập con là $\mathbf{2^n}$ với n đặc trưng. Biểu diễn một lựa chọn bằng **mảng nhị phân** (1 = đang được chọn, 0 = không). Với tập nấm 22 đặc trưng: 2^{22} = 4.194.304 tập con cần thử.
- **Sequential Forward Generation (SFG):** bắt đầu từ **tập rỗng**, lần lượt thêm đặc trưng X cho hàm mục tiêu cao nhất khi kết hợp với tập hiện tại Y_k. Tốt khi tập tối ưu có **ít** đặc trưng. Nhược điểm: không loại được đặc trưng trở nên lỗi thời sau khi thêm đặc trưng khác.
- **Sequential Backward Generation (SBG):** bắt đầu từ **tập đầy đủ**, lần lượt bỏ đặc trưng làm hàm mục tiêu giảm ít nhất. Tốt khi tập tối ưu có **nhiều** đặc trưng. Nhược điểm: không đánh giá lại đặc trưng đã bị bỏ.
- **Nâng cao:** xem chọn đặc trưng là bài toán tìm kiếm: **Genetic Algorithm** (gene, chromosome, population; lai ghép giữa các chromosome nhị phân) và **Particle Swarm Optimization** (từ lần lặp 0 các hạt phân tán, đến lần lặp N hội tụ).
- Sơ đồ tổng kết (DL03b): filter (missing value, information gain, chi-square test, Fisher's score), embedded (regularization L1/L2, random forest importance), wrapper (forward, backward, exhaustive feature selection, recursive feature elimination). Linear models như SVM và Lasso cũng được nêu ở nhóm multivariate.

6.5. So sánh nhanh

Tiêu chí	Feature extraction	Feature selection	Feature construction
Chiều	Giảm (d → m)	Giảm	Tăng/đổi
Đặc trưng kết quả	Mới (tổ hợp/biến đổi)	Tập con của đặc trưng gốc	Mới (từ phép toán trên đặc trưng gốc)
Diễn giải	Khó (mất danh tính)	Giữ	Tùy
Ví dụ	PCA, ICA, LDA, kernel PCA, autoencoder, t-SNE	Pearson, chi², MI, RFE, SFG/SBG, GA, PSO	x1×x2, (x1+x2)×x3, GP
Rủi ro/lưu ý	Mất thông tin; khó giải thích	Univariate bỏ qua tương tác; không chắc có ích	Có thể thêm lỗi, tăng phức tạp; cần đánh giá

TỰ KIỂM TRA CỦA BƯỚC NÀY

- **Đối chiếu nguồn:** DL03c (feature construction, GP, PCA/ICA/kernel PCA/autoencoder, bảng imaginary example), DL03b trang 26–42 (extraction, selection, bảng độ đo, sơ đồ tổng kết), DL03a trang 36–41 (curse, PCA, ISOMAP, embedding, subset selection, feature creation). Đã kiểm bằng code: χ^2 của ví dụ, 2^{22}.
- **Ý tác giả và của mình:** định nghĩa, danh sách kỹ thuật, quan điểm về GP và dud trees là của slide. Cột 'Diễn giải' của bảng heart disease, đáp án ICA, xếp loại kernel PCA/ISOMAP/t-SNE, tính χ^2 đầy đủ, nhận xét Spearman là của mình (đã gắn nhãn).
- **Lỗi trong slide:** 'autoencocers' (autoencoders), 'Principle Component' (Principal), 'T-SNA' (t-SNE), 'perdiction', 'Fearture'.
- **Thiên kiến:** mình có xu hướng gom thành bảng, dễ làm phẳng sắc thái. Với các câu hỏi lý thuyết 'vì sao', nên đọc lại slide gốc.
- **Chắc chắn:** cao cho định nghĩa và công thức. Trung bình cho: cách đọc sơ đồ phân loại độ đo theo kiểu biến, vị trí dấu ngoặc 'superfluous', nội dung hình Wine và hình 'Variable Selection' (mình chỉ có chữ và mô tả, chưa xem trực tiếp ảnh của DL03b, DL03c).

BƯỚC 7

Mô hình hóa và đánh giá

Ghép các bước trước thành một quy trình không rò rỉ dữ liệu

7.1. Những gì slide nói liên quan đến bước này

- **Yêu cầu dữ liệu phụ thuộc thuật toán** (DL03b): các công cụ ML dùng định dạng khác nhau; các phương pháp ML có yêu cầu khác nhau.
- **Generalisation so với overfitting**: mục tiêu là mô hình tổng quát hóa được sang dữ liệu mới; dùng test (và validation) để đo (xem bước 4).
- **Ước lượng hiệu năng**: tập test hoặc trung bình K-fold (ví dụ tỉ lệ lỗi). Hiệu năng ước lượng sẽ **sai** nếu có data leakage.

Biểu đồ 'What goes into a successful model' (DL03c, nguồn elitedatascience.com)

Thành phần	Tỉ trọng
Exploratory analysis	10%
Data cleaning	20%
Feature engineering	25%
Algorithm selection	10%
Model training	15%
Other	20%

Tổng 100%. Đây là ước lượng điển hình của nguồn tham khảo trong slide ('data scientists typically spend a lot of time doing feature engineering'). Slide DL03b còn nói chuẩn bị dữ liệu chiếm hơn 80% dự án; hai số liệu đo các thứ khác nhau nên không so trực tiếp.

7.2. Yêu cầu dữ liệu theo nhóm thuật toán (tổng hợp từ slide)

Thuật toán/nhóm	Điều slide nói	Ý nghĩa với chuẩn bị dữ liệu
KNN, SVM, gradient descent	Bị ảnh hưởng mạnh bởi thang đo dữ liệu (DL03b)	Chuẩn hóa/standardise đặc trưng số.
Cây quyết định, thuật toán dựa trên luật	Ưa hoặc đòi hỏi đầu vào phân loại (DL03b)	Cân nhắc rời rạc hóa; nhưng slide DL03c lại cho rằng một số bộ học dùng được dữ liệu thiếu (hướng 4).
Clustering/độ đo khoảng cách	Chuẩn hóa để một biến không chi phối khoảng cách (DL03a); tính tương đồng chỉ trên thuộc tính không thiếu (DL03c)	Chuẩn hóa trước khi tính khoảng cách; chọn độ đo hợp kiểu dữ liệu (Gower cho hỗn hợp).
Gradient Boosting, kNN, Random Forests	Có thể xử lý giá trị thiếu (DL03c)	Có thể không cần imputation; xác nhận theo từng thư viện.
Mô hình tuyến tính (SVM, Lasso)	Dùng trong chọn đặc trưng multivariate (DL03b)	Hệ số dùng làm điểm quan trọng.

7.3. Quy trình tham chiếu không rò rỉ dữ liệu (checklist)

#	Việc cần làm	Lý do (nguồn)
1	Hiểu thang đo, loại dữ liệu; làm EDA	Chọn đúng công cụ tiền xử lý (DL03a)
2	Kiểm tra noise, outlier, trùng lặp, thiếu; xác định cơ chế thiếu	Cơ chế thiếu quyết định cách xử lý (DL03a, DL03c)
3	**Chia dữ liệu trước** (train/test, hoặc k-fold)	Tránh data leakage (DL03b)
4	Chỉ trên train: điền thiếu, mã hóa, chuẩn hóa, rời rạc hóa	Nguyên tắc leakage mở rộng (mình suy ra)
5	Tạo/giảm/chọn đặc trưng; chọn số đặc trưng bằng cross-validation	DL03b: chọn số đặc trưng bằng CV; DL03c: đánh giá đặc trưng mới
6	Huấn luyện, theo dõi bằng validation	DL03b
7	Đánh giá một lần trên test (hoặc trung bình k-fold)	DL03b

Ví dụ code minh họa (đã chạy thử)

PHÂN TÍCH CỦA MÌNH (không có trong slide)

- Slide **không có** đoạn code này. Đây là ví dụ mình viết để minh họa nguyên tắc 'chia trước, chuẩn bị sau' bằng sklearn Pipeline. Đã chạy thử trên dữ liệu giả lập (sklearn 1.8.0): CV trên train ≈ 0,857, test ≈ 0,878. Số liệu chỉ để xác nhận code chạy được, không có ý nghĩa thực nghiệm.

```
from sklearn.model_selection import train_test_split, cross_val_score
from sklearn.pipeline import Pipeline
from sklearn.compose import ColumnTransformer
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import OneHotEncoder, StandardScaler
from sklearn.feature_selection import SelectKBest, f_classif
from sklearn.linear_model import LogisticRegression

# 1) CHIA TRƯỚC
X_tr, X_te, y_tr, y_te = train_test_split(X, y, test_size=0.3,
                                          stratify=y, random_state=0)
# 2) CHU□N BỊ nằm TRONG pipeline (ch□ fit trên train)
prep = ColumnTransformer([
    ("num", Pipeline([("imp", SimpleImputer(strategy="mean")),
                      ("sc", StandardScaler())]), ["tuoi", "thu_nhap"]),
    ("cat", OneHotEncoder(handle_unknown="ignore"), ["thanh_pho"]),
])
model = Pipeline([("prep", prep),
                  ("fs", SelectKBest(f_classif, k=3)),   # chọn đặc trưng
                  ("clf", LogisticRegression())])
# 3) Đánh giá: CV ch□ trên train; test dùng cu□i cùng
print(cross_val_score(model, X_tr, y_tr, cv=5).mean())
print(model.fit(X_tr, y_tr).score(X_te, y_te))
```

PHÂN TÍCH CỦA MÌNH (không có trong slide)

- Tên tham số, phương pháp (SimpleImputer, StandardScaler, SelectKBest/f_classif) có xuất hiện trong slide. Việc đặt chúng trong Pipeline là thực hành chuẩn của sklearn, mình chưa đối chiếu với slide.
- Slide chưa bàn tới **chỉ số đánh giá** (accuracy, F1...) ngoài việc nhắc 'error rates'; phần này nằm ngoài ba file nên mình không bổ sung.

TỰ KIỂM TRA CỦA BƯỚC NÀY

- **Đối chiếu nguồn:** DL03c biểu đồ tỉ trọng (tổng 100%), DL03b các trang liên quan; bảng 7.2 tổng hợp từ các câu của slide.
- **Ý tác giả và của mình:** nội dung 7.1 là của slide. Bảng quy trình 7.3 là tổng hợp của mình; bước 4 là mở rộng nguyên tắc leakage. Code là của mình (đã chạy).
- **Chắc chắn:** cao cho tỉ trọng và nguyên tắc chia trước; trung bình cho mở rộng leakage (hợp lý nhưng slide không nêu); code đã chạy nhưng chỉ trên dữ liệu giả lập.
- **Giới hạn:** ba file không có nội dung về chọn mô hình, siêu tham số hay chỉ số đánh giá chi tiết, nên bước 7 ngắn hơn các bước khác.

PHỤ LỤC

A. Tổng hợp lỗi và điểm lệch trong slide

#	File	Nội dung	Cách xử lý khi ôn
1	DL03a	Ví dụ cosine: ghi ‖B‖ = 2,245; đúng là √6 ≈ 2,449 (kết quả 0,3150 vẫn đúng)	Dùng 2,449
2	DL03a	Bảng thang đo: ví dụ cột Ordinal lặp ví dụ Nominal	Dùng ví dụ ordinal ở trang 5
3	DL03a	'T-SNA', 'Principle Component'	Đọc là t-SNE, Principal
4	DL03c	Multiple imputation nói gộp kết quả phân tích; MICE bước 4 nói lấy trung bình các bộ dữ liệu	Nêu đúng theo slide được hỏi; ghi chú khác biệt
5	DL03b	KBinsDiscretizer(n_bin=...)	Mình nghĩ tham số đúng là n_bins; kiểm tra tài liệu sklearn (chưa xác minh)
6	DL03b	Dòng 'Leave-one-out cross validation:' để trống	Hiểu là K = số mẫu (kiến thức ngoài slide)
7	DL03b	Spearman mô tả 'nonlinear correlation'	Chính xác hơn: quan hệ đơn điệu (theo bước 2 của DL03a)
8	DL03b/c	'autoencocers', 'perdiction', 'Fearture', 'Categorial', 'Nomalisation', 'discreate'	Chỉ là lỗi chính tả
9	DL03c	Tên 'MAR' dễ gây nhầm (chính slide thừa nhận)	Nhớ là 'missing, conditionally at random'

B. Thuật ngữ Anh – Việt

Thuật ngữ	Nghĩa	Thuật ngữ	Nghĩa
attribute/feature	thuộc tính/đặc trưng	imputation	điền giá trị thiếu
object/instance	đối tượng/mẫu	outlier	điểm ngoại lai
nominal/ordinal/interval/ratio	thang định danh/thứ tự/khoảng/tỉ lệ	noise	nhiễu
data leakage	rò rỉ dữ liệu	overfitting	quá khớp
generalisation	tổng quát hóa	cross validation	kiểm chứng chéo
one-hot encoding	mã hóa one-hot	normalisation	chuẩn hóa về khoảng
standardisation (z-score)	chuẩn hóa z-score	discretisation/binning	rời rạc hóa
feature extraction	trích xuất đặc trưng	feature selection	chọn đặc trưng
feature construction	xây dựng đặc trưng	dimensionality reduction	giảm chiều
filter/wrapper/embedded	lọc/bao bọc/nhúng	latent space	không gian ẩn
MCAR/MAR/MNAR	thiếu hoàn toàn ngẫu nhiên / ngẫu nhiên có điều kiện / không ngẫu nhiên	KDE	ước lượng mật độ kernel

C. Câu hỏi tự kiểm tra (kèm đáp án gợi ý)

#	Câu hỏi	Đáp án gợi ý
1	Phân biệt nominal, ordinal, interval, ratio, mỗi loại cho một ví dụ.	Nominal: màu mắt; ordinal: xếp hạng; interval: nhiệt độ °C; ratio: nhiệt độ Kelvin, tiền, số đếm (bước 2.1).
2	Vì sao median và IQR 'bền vững' còn mean và variance thì không?	Mean và variance bị kéo bởi outlier; median và IQR dựa trên vị trí/phân vị (bước 2.3).
3	Khi nào dùng Jaccard thay SMC?	Vector nhị phân thưa: Jaccard bỏ qua khớp 0-0 (bước 2.5). Ví dụ slide: SMC = 0,7 trong khi Jaccard = 0.
4	Vì sao phải chuẩn hóa trước khi tính khoảng cách Euclid?	Biến có thang lớn sẽ chi phối khoảng cách (bước 2.5).
5	Nêu ba vấn đề chất lượng dữ liệu và hai cách phát hiện.	Noise/outlier, thiếu, trùng; phát hiện bằng thống kê và trực quan hóa (bước 3.1).
6	Phân biệt MCAR, MAR, MNAR bằng ví dụ.	MCAR: phiếu mất do bọ; MAR: nam ít điền nhưng không liên quan mức trầm cảm sau khi tính giới tính; MNAR: người trầm cảm ít điền khảo sát trầm cảm (bước 3.3, ví dụ 2-3 là suy luận của mình).
7	Vì sao mean imputation bị xếp vào 'pretty bad'?	Dưới-biểu diễn độ biến thiên; làm đường hồi quy phẳng hơn (bước 3.4).
8	MICE gồm những bước nào, sklearn thực hiện bước nào?	4 bước; IterativeImputer thực hiện bước 1 và 2 (bước 3.4).
9	Data leakage là gì, thứ tự đúng của quy trình?	Thông tin tập giữ lại rò vào huấn luyện; chia → chuẩn bị → mô hình (bước 4.1).
10	Mô tả k-fold CV 5 fold.	Chia 5 phần, mỗi lần 1 phần test và 4 phần train, lặp 5 lần, lấy trung bình (bước 4.3).
11	Vì sao mã hóa dog→1, cat→2, ferret→3 không tốt?	Tạo thứ tự và khoảng cách giả cho dữ liệu nominal; dùng one-hot (bước 5.2, đáp án là suy luận của mình).
12	One-hot khác dummy encoding thế nào?	One-hot: N cột; dummy: N−1 cột (bước 5.2).
13	Khi nào normalise, khi nào standardise (theo slide)?	Phân phối chuẩn → standardise; ngược lại hoặc nghi ngờ → normalise (bước 5.3).
14	Tính equal-width với 14 giá trị nhiệt độ, N = 7.	W = (85−64)/7 = 3; số mẫu mỗi khoảng 2,2,4,2,0,2,2 (bước 5.4).
15	1R discretisation chọn điểm chia như thế nào?	Với mỗi điểm chia gán lớp đa số cho từng nhóm, tính lỗi, chọn điểm lỗi nhỏ nhất (bước 5.4).
16	Vì sao F3 = F1×F2 giúp phân loại?	Hai lớp ở các góc phần tư đối diện không tách tuyến tính; dấu của F1×F2 tách được bằng ngưỡng 0 (bước 6.2).
17	Genetic Programming để tạo đặc trưng có ưu nhược gì?	Linh hoạt nhưng không gian tìm kiếm ít cấu trúc, tốn thời gian thử 'dud trees'; không đảm bảo 'insight' (bước 6.2).
18	Extraction khác selection thế nào, đánh đổi gì?	Extraction tạo đặc trưng mới nhưng mất danh tính, khó diễn giải; selection giữ đặc trưng gốc (bước 6.3, 6.5).
19	PCA khác ICA ở điểm nào?	PCA khử tương quan, tìm phương biến thiên lớn nhất; ICA tìm thành phần độc lập thống kê (bước 6.3).
20	Kernel PCA giải quyết cái PCA không làm được là gì?	Dữ liệu không tách tuyến tính (hai vòng đồng tâm) (bước 6.3).
21	Filter, wrapper, embedded khác nhau thế nào?	Chọn trước mô hình / dùng bộ phân loại như hộp đen / chọn trong lúc xây mô hình (bước 6.4).
22	Hạn chế của univariate selection?	Bỏ qua tương tác giữa đặc trưng; không biết trước có hiệu quả; chọn số đặc trưng bằng CV (bước 6.4).
23	So sánh SFG và SBG.	SFG: từ rỗng, tốt khi tập tối ưu nhỏ, không bỏ được đặc trưng cũ; SBG: từ đầy đủ, tốt khi tập tối ưu lớn, không xét lại đặc trưng đã bỏ (bước 6.4).
24	Với 22 đặc trưng có bao nhiêu tập con?	2^{22} = 4.194.304 (bước 6.4).

D. Báo cáo tự kiểm tra tổng

Hạng mục	Kết quả
Đối chiếu nguồn	Mọi nội dung không gắn nhãn lấy từ DL03a (đã đọc toàn bộ lớp chữ 96 trang, xem hình các trang 6, 30, 34, 36, 43, 47, 56), DL03b và DL03c (đọc qua nội dung có sẵn trong cuộc trò chuyện). Mọi ví dụ số đã kiểm bằng code: cosine, SMC/Jaccard, khoảng cách, equal-width/depth, χ^2, 2^{22}, tổng tỉ trọng 100%.
Ý của tác giả slide và phân tích của mình	Tách bằng nhãn [Mình]. Phân tích của mình gồm: thứ tự 7 bước; mở rộng nguyên tắc leakage; đáp án một số câu hỏi slide để ngỏ; diễn giải bảng heart disease; χ^2 đầy đủ; nhận xét ưu nhược; code minh họa.
Thông tin bịa	Không thêm công thức, thuật toán hay số liệu ngoài slide, trừ phần đã gắn nhãn [Mình]. Hai chỗ kiến thức ngoài slide quan trọng nhất: LOO (K = số mẫu) và tham số n_bins; cả hai đã nêu rõ.
Thiên kiến	Có xu hướng cô đọng thành bảng (có thể làm mất sắc thái); có xu hướng lấp chỗ trống slide để ngỏ bằng đáp án hợp lý của mình. Các đáp án đó đều được gắn nhãn để bạn có thể bỏ qua.
Mức chắc chắn cao	Định nghĩa, công thức, bảng tóm tắt, ví dụ số.
Mức chắc chắn trung bình	Cách đọc hình DL03b/DL03c (mình chỉ có chữ và mô tả, chưa xem trực tiếp ảnh); sơ đồ phân loại độ đo theo kiểu biến; vị trí dấu ngoặc 'superfluous'; kết quả cụm k-means; số đọc từ đồ thị (3,3 và 0,15, 17 và 4).
Chưa xác minh	Tên tham số n_bins của sklearn; việc từng estimator sklearn có nhận NaN; các trang trực quan hóa DL03a (80–96) mình chưa xem từng hình; các phần 'Binarization' không có slide riêng.